

Chapitre 1 : Analyse de données

Économétrie (ECON0212)


Natalia Bermúdez

HEC Liège

September 2026

Utiliser des données

- Les **données** sont centrales en économétrie.



- Selon un **article du New York Times de 2014**, “les data scientists [...] passent de **50 % à 80 % de leur temps** plongés dans ce travail plus prosaïque de collecte et de préparation de données numériques rebelles, avant de pouvoir les explorer”
- Aujourd’hui : les basiques de l’analyse de données (préparation, visualisation et statistiques descriptives)**

Au menu de cette séance

1. Stata 101
2. Nettoyer les données
3. Transformations avancées (agrégations, combinaisons...)
4. Visualisation
5. Statistiques descriptives

Au menu de cette séance

1. **Stata 101**
2. Nettoyer les données
3. Transformations avancées (agrégations, combinaisons...)
4. Visualisation
5. Statistiques descriptives

Installation de **Stata**

Cf. [guide sur lola](#)

1. Téléchargement depuis DOX (version Stata **StataNow/SE**)

- Mot de passe = stata19hec
- Version Windows : <https://dox.uliege.be/index.php/s/dXvpvWNjR7KXSkX>
- Version Mac : <https://dox.uliege.be/index.php/s/Qrg86PtLILkOdeI>

2. Installation


- Lancer l'installateur et choisir la version **StataNow/SE**.
- Ensuite encoder les credentials ci-dessous :
 - Nom: Auchoix
 - Organization: HEC Liège
 - Authorization : rnje
 - Code : 0n0h kake \$m7k xomu 26h7 y0fm kd82 zm7t cc4yt

Stata

Y:AITCMITC market def

Glossaire

- **Stata** : le nom du logiciel qu'on va utiliser pendant tout le cours pour analyser des données
- Une **commande** : une instruction écrite que vous donnez à **Stata**, et que le logiciel comprend et exécute (-> ouvrir une base de données, créer une variable, calculer une moyenne...)
 - ⚠ Une seule commande par ligne
- Un **dofile** : un fichier texte (extension **.do**) qui contient une suite de commandes, écrites les unes en dessous des autres
 - Chaque commande doit être séparée par une nouvelle ligne
 - Stata lit et exécute les commandes dans l'ordre où elles apparaissent, de haut en bas



- Ouvrir un dofile :
- Pour lancer une commande écrite dans un dofile :
 - Sélectionner la ou les lignes à exécuter
 - Taper **Ctrl** + **D** (Windows) ou **Command** + **Shift** + **D** (Mac), ou cliquer sur **Do**

Exercice 1

05:00

1. Créer un nouveau dofile (File → New → Do-file). Sauvegarder quelque part sous le nom **1-analyse-de-donnees**.
2. Écrire le code suivant dans le dofile et compiler (**Ctrl** + **D** ou **Ctrl** + **Maj** + **D**).
(Vous pouvez surligner le code à compiler, ou compiler sur tout le dofile)

```
1 set obs 10 /* Génère 10 observations */  
2 gen x = 1 /* crée une variable nommée x et égale à 1 */
```

Bravo ! Vous avez créé votre première variable !

3. Créer une nouvelle variable **y** égale à x^2 .



Trouver de l'aide

- **Directement** dans **Stata** :

- *Limite* : il faut connaître le nom de la **commande** . Par exemple :

```
1 help regress  
2 help summarize
```


- Sur **internet** :

- Parfois plus efficace
- Il vaut mieux faire une recherche en anglais pour avoir plus de réponses
- Renvoie souvent sur la documentation officielle

- **Intelligence artificielle** (ChatGPT, Claude, Prodigy...) :

- Potentiellement encore plus efficace !
 - **Surtout utile quand on a déjà une idée de ce qu'on fait**
- Exemple d'utilisation

Collaborer!



Quand ça tourne mal

Du rouge ? C'est une erreur ! Que faire ?

1. **La lire** → souvent, la source de l'erreur est expliquée
2. La rechercher sur internet car $P(\text{quelqu'un a déjà eu cette erreur}) > 99\%$



```
1 . summarize salaire age educaton
2
3 variable educaton not found
4 r(111);
```

Importer des données

Stata peut importer des données depuis différents formats :

- Format Stata : extension **.dta**

```
1 use dataset_name.dta, replace
```

- Format Excel : extension **.xls** ou **.xlsx**

```
1 import excel using dataset_name.xlsx, firstrow replace
```

- Attention au format du fichier excel : une ligne est une observation, une colonne une variable

- Format CSV : extension **.csv**

```
1 import delimited using dataset_name.txt, delimiters(",") replace
```

- Chaque élément est séparé de l'ensemble des données par un **delimiter** qui peut être : une tabulation, une virgule, un point-virgule...

Importer des données : chemin absolu ou relatif?

1 Chemin absolu = l'adresse complète du fichier

On indique à Stata **exactement où se trouve le fichier** sur l'ordinateur.

```
1 * Windows
2 use "C:/Data/Projet/analyse/mydata.dta", clear
3
4 * macOS
5 use "/Users/alice/Data/Projet/analyse/mydata.dta", clear
```

Le chemin commence depuis la **racine de l'ordinateur**.

⚠ **Attention** : utilisez `/` dans les chemins. Cela fonctionne sous **Windows, macOS et Linux**.

2 Chemin relatif = l'adresse à partir du dossier de travail

Stata part du **répertoire de travail courant** (`cd`).

```
1 * Définir le dossier de travail
2 cd "C:/Data/Projet/analyse"
3
4 * mydata.dta se trouve dans ce dossier
5 use "mydata.dta", clear
```

Inspecter des données

Une fois l'ensemble de données chargé, vous pouvez commencer à l'explorer :

- **browse** : Ouvre les données dans la fenêtre d'exploration.
- **describe** : Affiche la liste des variables, leur type et leur étiquette.
- **codebook** : Fournit des informations détaillées sur les variables : type, valeurs manquantes, valeurs uniques, étendue, etc.
- **sum nom_de_la_variable** : Donne le nombre d'observations, la moyenne, l'écart-type, le minimum et le maximum.
- **sum nom_de_la_variable, detail** : Fournit des statistiques descriptives plus détaillées, notamment les percentiles, la médiane, l'asymétrie et l'aplatissement.
- **tab nom_de_la_variable** : Produit un tableau de fréquences indiquant le nombre d'observations pour chaque valeur de la variable.

Exercice 2

05:00

1. **Importez** la base `gapminder.dta` en format dta (disponible sur lola).
 - Cette base contient des données sur l'espérance de vie et le PIB par habitant de nombreux pays.
 2. **Quelles variables** contiennent les données ? Vous pouvez utiliser `codebook` ou `describe`.
 3. **Inspectez visuellement** les données. Plusieurs solutions pour ouvrir la base de données grâce à `browse` :
 1. Naviguer dans le menu : `Data, Data Editor`
 2. Bouton `browse`
 3. Commande : `browse [varlist] [if]` dans la fenêtre de commande ou un dofile
- À quoi correspond la variable `pop` ? Quel pays compte le moins d'habitants ?

Types de variables

- **Numérique** (`float` , `int`) :
 - Exemple : âge → `int` ; revenu → `float`
- **Texte** (`string`) :
 - Exemple : pays, nom → `string`
- **Catégorielle** :
 - Exemple : genre
 - Une variable numérique avec un label pour chaque valeur
 - `1="female"` ; `2="male"`

Modifier le type de la variable

- texte → numérique

```
1 destring nom_de_la_variable, replace
```

- numérique → texte

```
1 tostring nom_de_la_variable, replace
```

- texte → catégoriel

```
1 encode nom_de_la_variable, gen(variable_encodee)
```

Modifier des données existantes (variables)

- Supprimer une variable (ou une liste de variables)

```
1 drop variable_1 variable_2
```

- Sélectionner une variable (ou une liste de variables) [ce qui supprime les autres]

```
1 keep variable_1 variable_2
```

- Renommer une variable :

```
1 rename ancien_nom nouveau_nom
```

- Créer un label :

```
1 label var nom_de_la_variable "Label de la variable"
```

Créer des variables

- On génère une nouvelle variable en lui donnant un nom et en définissant ses valeurs dans une **EXPRESSION**

```
1 gen nouvelle_variable = EXPRESSION
```

- Une **EXPRESSION** peut être :
 - Mathématique, par exemple :

```
1 gen variable1 = 200
2 gen variable2 = variable1*2
```

- Du texte (**string** en **Stata**), par exemple :

```
1 gen variable1 = "coucou"
```

- Une fonction de variables existantes :

```
1 gen variable3 = (variable1 + variable2)/2
```

Modifier la valeur d'une variable

- On peut remplacer la valeur d'une variable (très similaire à `gen`)
- Une fonction de variables existantes :

```
1 replace une_variable_qui_existe = EXPRESSION
```

- Remplacement conditionnel :

```
1 replace age_category = "old" if age > 70
```

Expressions logiques

- Expressions qui peuvent être utilisées pour préciser la condition :

- `==` : égal à
- `!=` : non égal à
- `<=` : inférieur ou égal à
- `>=` : supérieur ou égal à
- `<` : strictement inférieur à
- `>` : strictement supérieur à

- Pour combiner ces conditions, on utilise `&` ou `|` :

- `&` = *et* : si les 2 conditions doivent être vérifiées toutes les deux

```
1 gen age_category = "old" if age > 70 & age < 110
```

- `|` = *ou* : si une des conditions seulement doit être vérifiée

```
1 gen etudianthec = "bac" if filiere=="IG" | filiere=="SEG"
```

Sélection d'observations

- Garder ou supprimer les observations sous certaines conditions

```
1 keep if CONDITION
2 drop if CONDITION
```

- Par exemple :

```
1 /* Sélectionne les pays du continent américain */
2 keep if continent=="Americas"
3
4 /* Supprime les pays américains sauf l'Argentine */
5 drop if continent=="Americas" & country!="Argentina"
```

⚠ Comme c'est le cas dans de nombreux logiciels, l'expression logique s'écrit ==

Exercice 3

05:00

1. Combien d'**observations** y a-t-il dans la base de données ouverte précédemment (**gapminder**) ?
2. Combien de **variables** ? De quel type ?
3. Ne gardez que les observations correspondant au continent **Asia**.
4. Chargez à nouveau la base, puis créez la variable **gdppercap** égale au PIB par habitant grâce au code suivant :

```
1 gen gdppercap = gdp / population
```

Félicitations, vous avez créé votre première variable ! Utilisez la commande **browse** pour la voir dans la base.

Syntaxe de Stata

La plupart des commandes ont la syntaxe suivante :

`command [varlist] [if] [, options]`

où [...] correspond à des options. *Exemples :*

- `summarize` ou juste `sum` — statistiques descriptives pour toutes les variables
- `summarize gdp` — statistiques descriptives pour le `gdp` uniquement
- `summarize gdp if year == 1960` — statistiques descriptives pour le `gdp` en 1960



Au menu de cette séance

1. Stata 101
2. **Nettoyer les données**
3. Transformations avancées (agrégations, combinaisons...)
4. Visualisation
5. Statistiques descriptives

Valeurs manquantes

- Quand une valeur est manquante, elle est indiquée
 - `.` pour une variable numérique
 - `""` pour une variable string
- **Dans les calculs**, une valeur manquante produit généralement une valeur manquante :

```
1 display . + 10
```

- **Stata** assigne la valeur $+\infty$ à une valeur manquante :

Attention à la propagation des valeurs manquantes ! :

	country	year	population	gdp	gdppercap
1	Albania	1960	1636054	.	.
2	Algeria	1960	11124892	1.383e+10	1.54e+17
3	Angola	1960	5270844	.	.
4	Antigua and Barbuda	1960	54681	.	.
5	Argentina	1960	20619075	1.083e+11	2.23e+18



Au menu de cette séance

1. Stata 101
2. Nettoyer les données
3. **Transformations avancées (agrégations, combinaisons...)**
4. Visualisation
5. Statistiques descriptives

Agrégation des données **collapse**

La commande collapse transforme la base de données en mémoire en statistiques essentielles sur celle-ci (**sum** => somme ; **mean** => moyenne ; **sd** => écart-type ; **median** => médiane).

country	year	lifeexp
A	1	70
A	2	71
B	1	80
B	2	82
B	3	85
C	1	79
C	2	82
C	3	81



year	lifeexp
1	76,33
2	78,33
3	83,00

collapse (mean) lifeexp, by(year)

- Attention, **collapse** remplace les données en mémoire

Combiner des bases de données : **append**


economy2004.dta					
country	GDP per Capita	year			
ARG	12,468	2004			
FRA	27,913	2004			
GER	28,889	2004			
ITA	28,172	2004			
USA	39,498	2004			

economy2005.dta					
country	GDP per Capita	year			
ARG	13,153	2005			
FRA	29,203	2005			
GER	30,15	2005			
ITA	29,414	2005			
USA	41,557	2005			

Appended					
country	GDP per Capita	year			
ARG	12,468	2004			
FRA	27,913	2004			
GER	28,889	2004			
ITA	28,172	2004			
USA	39,498	2004			
ARG	13,153	2005			
FRA	29,203	2005			
GER	30,15	2005			
ITA	29,414	2005			
USA	41,557	2005			

- 1 `use economy2004.dta, replace`
- 2 `append using economy2005.dta`


Combiner des bases de données : **merge**



```
1 use economy2004.dta, replace
2 merge 1:1 country using economy2005.dta
```

Formats wide et long: **reshape**

country	Long		lifeexp
	year		
A	1		70
A	2		71
B	1		80
B	2		82
B	3		85
C	1		79
C	2		82
C	3		81



Wide			
year	lifeexpA	lifeexpB	lifeexpC
1	70	80	79
2	71	82	82
3	.	85	81

- Long → Wide

```
1 reshape (wide) lifeexp, i(year) j(country)
```

- Wide → Long

```
1 reshape (long) lifeexpA lifeexpB lifeexpC, i(year) j(country)
```

Exercice 4 : Nettoyage des données

05:00

On utilise la base `gapminder` précédemment importée.

1. Quelles années ont des valeurs manquantes pour le PIB ?
2. Quel pays a l'espérance de vie la plus élevée pour une population de plus d'un milliard en 2007 ?
3. Quelle est la moyenne de l'espérance de vie par continent et par an ? (Vous pouvez utiliser la fonction `collapse`)


Syntaxe de collapse : `collapse (mean) VAR1 VAR2 VAR3, by(VAR_CATEGORIELLE)`



Au menu de cette séance

1. Stata 101
2. Nettoyer les données
3. Transformations avancées (agrégations, combinaisons...)
4. **Visualisation**
5. Statistiques descriptives

Visualiser des données



Comment choisir la représentation graphique adaptée ?

Ça dépend des variables étudiées, et notamment :


- 1, 2 (ou 3) variables
- Continue ou discrète

Visualiser des données — 1 variable

Variable continue


Histogramme : visualiser la distribution d'une variable

```
1 histogram wage
```



Densité : visualiser la distribution d'une variable

```
1 kdensity time_worked
```




Visualiser des données — 1 variable

Discrète

- *Diagramme en bâton* (*bar chart*) :
 - Si la variable discrète est numérique :

```
1 graph bar (count), over(nb_enfants)
```



Visualiser des données — 2 variables

Scatter plot : montrer les valeurs d'une variable en fonction de l'autre

```
1 twoway scatter gdp gini_ineq
```





Diagramme en bâton (bar chart) : variable quantitative selon les valeurs d'une variable qualitative (ou catégorielle)

```
1 graph bar (mean) wage, over(type_contract)
```



Une base de données “propre”

1. Chaque *colonne* correspond à une variable
2. Chaque *ligne* correspond à une observation

Avant de procéder à la visualisation, il faut se demander :

1. Quelle information veux-je représenter ?
 - Faire en particulier attention à la présence de potentielles variables manquantes

```
1 misstable summarize gdp fertility life_expectancy
```

2. Est-ce que les données contiennent cette information telle qu'*une colonne/ligne* correspond à ce que je veux représenter ?
 - Éventuellement utiliser **collapse** et/ou **reshape** pour transformer les données

Types de visualisation

Quelques exemples des types de graphiques les plus utilisés :

- Commande **twoway** + type de graphique

TYPE	FONCTION
Point	scatter
Line	line , connected
Histogram	histogram
Density	kdensity

- Commande **graph** + type de graphique

TYPE	FONCTION
Bar	bar
Boxplot	box

Exercice 5 : Premiers graphiques

05:00

On utilise les données `gapminder`.

1. L'histogramme des espérances de vie en 2007. Ensuite, précisez la couleur en ajoutant l'option `color(green)` (*il faut mettre les options après une virgule*).
2. Un **scatter plot** du taux de fertilité (axe y) vs. PIB par habitant (axe x) en 2007. Ensuite, spécifiez les titres des axes.
3. [CHALLENGE] Représentez l'évolution de l'espérance de vie au cours du temps par continent.
 - Il va falloir agréger les données au niveau continent $\times$ year $\rightarrow$ vous pouvez faire cela avec une commande `collapse`
 - Il est ensuite plus simple de changer la forme des données pour les transformer de "long" en "wide" en utilisant un `reshape`



Au menu de cette séance

1. Stata 101
2. Nettoyer les données
3. Transformations avancées (agrégations, combinaisons...)
4. Visualisation
5. **Statistiques descriptives**

Synthétiser les données

- En général, on apprend à connaître ses données par des visualisations + calculs de statistiques descriptives
- C'est l'heure des **statistiques descriptives** !
 - Utilisées pour décrire les données et simplifier l'information à partir de différentes mesures, tableaux et graphiques
 - (VS. **statistiques inférentielles** qui permettent ensuite de généraliser les résultats à la population d'intérêt.)
- En particulier, nous nous intéressons aux **tendances centrales** et à la **dispersion**.

Tendances centrales

mean(x) : la moyenne de toutes les valeurs de **x**.

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

```
1 set obs 100
2 gen y = rnormal()
3 egen y_mean=mean(y)
4 summ y_mean
```

Médiane : la valeur de x_j qui partage les observations en 2 parties égales (50 % au-dessus, 50 % en dessous). m est la médiane si

$$\Pr(X \leq m) \geq 0.5 \text{ et } \Pr(X \geq m) \geq 0.5$$

La médiane est robuste à la présence de valeurs *extrêmes*.

```
1 egen y_p50=median(y)
2 summ y_p50
```


Dispersion

Une autre caractéristique intéressante est la mesure de l'écart d'une variable par rapport à son centre (la moyenne dans ce cas).

La **variance** est l'une de ces mesures (**l'écart interquartile** en est une autre).

$$Var(X) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

Soit deux **distributions normales** ayant une moyenne égale à **0** :



Commande :

```
1 egen sd_x = sd(x)
2 generate y_var = sd_x^2
```

Statistiques descriptives : les commandes Stata

Variables numériques

La commande **summarize** (**sum**) permet d'afficher des statistiques de base sur une ou plusieurs variables numériques de la base de données :

- la moyenne, l'écart-type et les valeurs extrêmes (min et max)
- L'option **detail** permet d'afficher des statistiques plus précises sur la distribution de la ou des variables : médiane et autres centiles.

```
1 summarize gdp population, detail
```

Statistiques descriptives : les commandes Stata

Variable discrète

tabulate (**tab**) permet d'afficher les tableaux de fréquences (i.e., la distribution) des variables numériques catégorielles ou des variables textuelles :

```
1 tabulate country
```

Statistiques croisées

Deux variables catégorielles


Dans le cas où il y a 2 variables spécifiées, `table` produit une table de contingence :

```
1 table year country
```

Deux variables : catégorielle vs. quantitative

```
1 tabstat fertility, by(year)
```

Comment x et y sont associées ? Covariance et corrélation



On s'intéresse principalement à 2 statistiques pour caractériser la relation entre x et y :

1. Covariance
2. Corrélation

Covariance

- La covariance est une mesure de la **variabilité jointe** de deux variables.

$$Cov(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})$$

- Difficile à interpréter car sensible à la dispersion des variables par rapport à la moyenne.

Corrélation

- La corrélation est une mesure de la force de l'**association linéaire** entre deux variables.

$$Cor(x, y) = \frac{Cov(x, y)}{\sqrt{Var(x)}\sqrt{Var(y)}}$$

- La fonction **cor** calcule la corrélation :


```
1 cor infant_mortality fertility
```

- On ajoute l'option **cov** si on veut la covariance

```
1 cor infant_mortality fertility, cov
```

Corrélation

- La **corrélation** est toujours entre -1 et 1 !



Un autre source : *mathisfun*

Exercice 6 : statistiques descriptives

1. Quelle est la moyenne du PIB en 2011 ?
2. La médiane ?
3. Calculez la moyenne de l'espérance de vie par année.
4. Calculez la corrélation entre la fertilité et la mortalité infantile en 2015.

[À retenir] Utiliser des do files

Dofile = un script contenant une suite de commandes Stata

- **Commande vs. script**

- Ligne de commande : pratique pour tester
- Script de commandes (= **dofile**) :
 - permet à l'analyse d'être reproductible
- Commenter ses dofiles : **//**

```
1 di 1+1 // commentaire sur une ligne
2
3 /*
4 Commentaire sur plusieurs lignes
5 */
```

⇒ **toujours** utiliser un script

- Organiser son travail en **plusieurs dofiles**

- ayant une suite logique :
 - créer la base de données → statistiques descriptives → analyse graphique
- ayant des noms significatifs :
 - **1-construction-data.do** → **2-stat-des.do** → **3-graph.do**

[À retenir] Commandes principales en Stata

TÂCHES	COMMANDES
Obtenir de l'aide	<code>help</code> , <code>findit</code> , <code>lookfor</code>
Utiliser les données Stata	<code>use</code> , <code>save</code> , <code>append</code> , <code>merge</code>
Gestion des données	<code>reshape</code> , <code>collapse</code>
Gérer les variables	<code>replace</code> , <code>rename</code> , <code>encode</code> , <code>sort</code> , <code>keep</code> , <code>drop</code>
Gérer les observations	<code>keep if</code> , <code>drop if</code>
Créer/modifier des variables	<code>generate</code> , <code>replace</code> , <code>egen</code>
Visualiser les données	<code>describe</code> , <code>list</code> , <code>tabulate</code> , <code>summarize</code>
Calculatrice	<code>display</code>

Question de compréhension [Groupe de 2]

Choisissez un graphique issu d'un média grand public (article, journal, site internet, rapport) qui concerne une statistique ou une donnée économique. Précisez les éléments suivants :

- La source et le contexte du graphique.
- Une description de ce que représente ce graphique.
- Ce que vous trouvez pertinent ou problématique dans ce graphique.
- Comment ce graphique peut être interprété ou discuté du point de vue de l'analyse économique et statistique.
- Suggérez une analyse statistique complémentaire

Liste de sources



lien

Où en sommes-nous de notre quête de la causalité ?

- ✓ **Comment gérer les données ?** Regardez-les, ordonnez-les, visualisez-les...
- ✗ Comment résumer une relation entre plusieurs variables ?
- ✗ Qu'est-ce que la causalité ?
- ✗ Comment faire si nous n'observons qu'une partie de la population ?
- ✗ Nos résultats sont-ils uniquement dus au hasard ?
- ✗ Comment trouver de l'exogénéité en pratique ?

À la semaine prochaine !

CONTACT

natalia.bermudez@uliege.be

Un grand merci à [Malka Guillot](#) pour avoir partagé les supports de ce cours, ainsi qu'à [Florian Oswald](#) et à toute l'équipe de ScPoEconometrics pour leur livre et leurs [ressources](#).