

Chapitre 2 : Régression linéaire simple (RLS)

Économétrie (ECON0212)

Natalia Bermúdez

HEC Liège

October 2026

Recap — Analyse de données

05:00

Wooclap



lien de participation (code : **EFAIRJX**)



Aujourd'hui — on commence l'économétrie 🙌

- Introduction au modèle de *régression linéaire simple* et à l'estimation par *moindres carrés ordinaires (MCO)*.
- Application empirique : *taille de la classe* et *performance des élèves*.
- Gardez à l'esprit que nous cherchons à découvrir des relations **causales**.

Plan du cours

1. **Introduction I : l'intuition derrière la droite de régression**
2. Introduction II : formalisation modèle de régression linéaire simple
3. Estimation par moindres carrés ordinaires (MCO)
4. Le modèle de régression linéaire simple (et hypothèses)
5. Estimation en Stata
6. Propriétés algébriques de l'estimateur des MCO

Taille de la classe et performance des élèves

Quelles politiques *conduisent* à une amélioration de l'apprentissage des élèves ?

- La **réduction de la taille des classes** est au cœur des débats politiques depuis des *décennies*.
- Des classes plus petites pourraient permettre aux enseignants de consacrer davantage de temps à chaque élève, mais leur mise en place est coûteuse.

Application : données d'un célèbre article de Joshua Angrist et Victor Lavy (1999)



- Obtenues du cours de Raj Chetty et Greg Bruich
- **Contexte**
 - Classes d'élèves de 10-11 ans des écoles élémentaires publiques juives en Israël en 1991
- **Données**
 - Résultats aux tests nationaux qui mesurent les compétences en mathématiques et en lecture (hébreu). Les scores bruts sont échelonnés de 1 à 100.
 - Caractéristiques des classes/écoles.

Exercice 1 : découvrir les données

07:00

1. Ouvrir la base `grade5.dta` qui se trouve dans le dossier `exercice` de ce chapitre (sur LOLA).
2. Examiner les données :
 - Quelle est l'unité (l'entité) d'observation, c'est-à-dire à quoi correspond chaque ligne ?
 - Combien d'observations y a-t-il ?
 - Regardez la base. Quelles variables avons-nous ? À quoi correspondent les variables `avgmath` et `avgverb` ?
3. Avez-vous un *a priori* sur la relation réelle (linéaire) entre la taille des classes et les résultats des élèves ? Que feriez-vous pour obtenir un premier aperçu ?



Taille de la classe et performance des élèves — scatter plot



- Suggère une association plutôt positive.
- **Comment pouvons-nous visualiser cette relation plus clairement ?**

Taille de la classe et performance des élèves — *binned scatter plot*

Score moyen par taille de classe.




Taille de la classe et performance des élèves — droite de régression

Concentrons-nous sur les résultats en mathématiques !

Comment **résumer (et visualiser)** la relation entre les deux variables ?


- Une possibilité : **tracer une droite qui résume au mieux le nuage de points.**



- Mais **quelle droite choisir** ?
 - Celle-ci est horizontale : elle suppose que le score moyen en mathématiques ne varie pas avec la taille de la classe. 😞

Taille de la classe et performance des élèves — droite de régression

Tracer une droite qui résume au mieux le nuage de points.



- Celle-ci ?
- Un peu mieux ! Elle a une **pente** et une **ordonnée à l'origine** 😐
- **Il nous faut une règle de décision !**
- 🎯 À vous de trouver la meilleure droite !

Plan du cours

1. Introduction I : l'intuition derrière la droite de régression
2. **Introduction II : formalisation modèle de régression linéaire simple**
3. Estimation par moindres carrés ordinaires (MCO)
4. Le modèle de régression linéaire simple (et hypothèses)
5. Estimation en Stata
6. Propriétés algébriques de l'estimateur des MCO

Régression linéaire simple — formalisation

Nous nous intéressons à la relation entre deux variables :

- Une **variable expliquée** (y)
 - Également appelée **variable dépendante**, variable expliquée, variable de résultat, variable prédite, variable endogène :
 - *Score moyen en mathématiques*
- Une **variable explicative** (x)
 - Également appelée **variable indépendante** ou **régresseur**, variable prédictive, variable exogène, variable de contrôle :
 - *Taille de la classe*
- Pour chaque classe i (c.-à-d. chaque observation), nous observons à la fois x_i et y_i .

Régression linéaire simple — formalisation

- Pour estimer le modèle de régression, on a besoin de données.
- Échantillon *aléatoire* de n observations :
 - $(x_1, y_1) \longleftarrow$ Observation 1
 - $(x_2, y_2) \longleftarrow$ Observation 2
 - $\dots$
 - $(x_n, y_n) \longleftarrow$ Observation n
- De manière équivalente :
$$\{(x_i, y_i) : i = 1, \dots, n\}$$

Régression linéaire simple — formalisation


- Nous cherchons à résumer la relation entre x et y à l'aide d'une droite (pour l'instant).
- L'équation d'une telle droite, avec une **ordonnée à l'origine** b_0 et une **pente** b_1 , est :

$$\hat{y}_i = b_0 + b_1 x_i$$

- $\hat{y}_i$ est la valeur prédite (**prédiction**) de y pour l'observation i , à partir de cette droite (c.-à-d. de notre modèle).


Mais comment choisir b_0 et b_1 pour que la droite représente au mieux les données ?

[Rappel] Qu'est-ce qu'une droite ?



Régression linéaire simple : résidus


- Si tous les points étaient **sur** la droite, alors $\hat{y}_i = y_i$:



- **Une prédiction parfaite !** Il n'y a **pas d'erreur de prédiction**, le modèle explique **parfaitement** les observations.

Régression linéaire simple : résidus

- Si tous les points étaient **sur** la droite, alors $\hat{y}_i = y_i$:



- **Une prédiction parfaite !** Il n'y a **pas d'erreur de prédiction**, le modèle explique **parfaitement** les observations.

Régression linéaire simple : résidus

- Si tous les points étaient **sur** la droite, alors $\hat{y}_i = y_i$.
- Dans **la plupart des cas**, la *variable dépendante* (y) n'est pas *parfaitement* expliquée par la *variable indépendante* choisie (x) :

$$\hat{y}_i \neq y_i$$

- L'écart entre la valeur observée et la valeur prédite $\Rightarrow$ **résidu**
- Pour chaque observation i , on note ce résidu $\hat{e}_i$:


$$\hat{e}_i = y_i - \hat{y}_i$$

Régression linéaire simple : résidus


- Les *données réelles* peuvent donc être écrites comme **prédiction + résidu** :

$$y_i = \hat{y}_i + \hat{e}_i = b_0 + b_1 x_i + \hat{e}_i$$

Régression linéaire simple : graphiquement



Régression linéaire simple : graphiquement



Régression linéaire simple : le terme d'erreur

- Le modèle économétrique **vis**e à expliquer y en fonction de x ($\rightarrow$ **observé**) :


$$y_i = \beta_0 + \beta_1 x_i + e_i$$

- Mais x n'est généralement **pas le seul facteur** qui explique y .
- On regroupe dans le **terme d'erreur** e_i tous les autres facteurs qui affectent y_i :

$$y_i = \underbrace{\beta_0 + \beta_1 x_i}_{\text{partie expliquée par } x_i} + \underbrace{e_i}_{\text{autres facteurs}}$$

- **Exemple** : ... e_i peut inclure les caractéristiques de l'enseignant, les capacités de l'élève, son environnement familial, etc.

Régression linéaire simple : graphiquement



**Comment choisir la droite qui
représente le mieux nos données ?
Quel critère de minimisation
pouvons-nous utiliser ?**

Plan du cours

1. Introduction I : l'intuition derrière la droite de régression
2. Introduction II : formalisation modèle de régression linéaire simple
3. **Estimation par moindres carrés ordinaires (MCO)**
4. Le modèle de régression linéaire simple (et hypothèses)
5. Estimation en Stata
6. Propriétés algébriques de l'estimateur des MCO

Estimation par Moindres Carrés Ordinaires (MCO)

En anglais : Ordinary Least Squares (OLS).

- Les résidus de signes différents (+/−) s'annulent ; nous considérons donc les **résidus au carré** :

$$\forall i \in [1, n], \quad \hat{e}_i^2 = (y_i - \hat{y}_i)^2 = (y_i - b_0 - b_1 x_i)^2$$

- Choisir (b_0, b_1) de manière à ce que $\sum_{i=1}^n \hat{e}_i^2 = \hat{e}_1^2 + \dots + \hat{e}_n^2$ soit **aussi petit que possible**, i.e. :

$$\min_{b_0, b_1} \sum_{i=1}^n \hat{e}_i^2 \quad \text{ou} \quad \min_{b_0, b_1} \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

Estimation par Moindres Carrés Ordinaires (MCO)

Ajustez la droite

Choisissez b_0 et b_1 pour rendre la somme des carrés des résidus (SCR) la plus petite possible.

Ordonnée à l'origine b_0

0,5

Pente b_1

-1,0

$\hat{y} = 0,5 - 1,0 \cdot x$

SCR = 1868,97


Encore 1851,68 au-dessus du minimum atteignable

Déplacez les curseurs pour réduire la SCR.

☒ Afficher les carrés des résidus

☐ Afficher la droite MCO

Réinitialiser



Moindres Carrés Ordinaires (MCO) :

- **MCO** : méthode d'*estimation* consistant à minimiser la somme des résidus au carré.
- Fournit des solutions **uniques** à ce problème de minimisation.
- Alors, quelles sont les formules pour b_0 (constante) et b_1 (pente) ?
- Dans le cas où nous n'avons qu'une seule variable indépendante :

Pente :
$$b_1 = \frac{\text{cov}(x, y)}{\text{var}(x)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Constante :
$$b_0 = \bar{y} - b_1 \bar{x}$$

- **Démonstration** : résolution du problème de la minimisation de la somme des carrés des résidus. Cf. Wooldridge, André et Beine (2018), annexe 2A¹ et **vidéo**.

1. Wooldridge, J. M., André et Beine (2018). *Introduction à l'économétrie*. Chapitre 2, annexe 2A.

Moindres Carrés Ordinaires (MCO) — interprétation

Pour l'instant, supposons que les variables dépendante (y) et indépendante (x) sont numériques.

Ordonnée à l'origine (b_0) : **valeur prédite de y ($\hat{y}$) lorsque $x = 0$** (ou constante).

Pente (b_1) : **le changement prédit, en moyenne, dans la valeur de y associé à une augmentation d'une unité de x .**

$$\frac{\Delta y}{\Delta x} = b_1$$

I.e., de combien la variable dépendante change-t-elle si la variable indépendante augmente d'une unité ?

- Les **unités** de x sont importantes pour l'interprétation de b_1 : elles affectent sa magnitude, mais pas son signe.
- Il faut donc toujours être explicite sur **l'unité de mesure de x** .

Moindres Carrés Ordinaires (MCO) — interprétation causale ?

⚠ Nous utilisons le terme « **associé** », **en évitant clairement d'interpréter b_1 comme l'impact causal de x sur y .**

Pour faire une telle affirmation, certaines conditions spécifiques doivent être remplies.

(Voir chapitre « Causalité » !)

Plan du cours

1. Introduction I : l'intuition derrière la droite de régression
2. Introduction II : formalisation modèle de régression linéaire simple
3. Estimation par moindres carrés ordinaires (MCO)
4. **Le modèle de régression linéaire simple (et hypothèses)**
5. Estimation en Stata
6. Propriétés algébriques de l'estimateur des MCO

[Définition] Modèle de la régression linéaire simple

Modèle économétrique (RAPPEL !)

$$y_i = \beta_0 + \beta_1 x_i + e_i$$

- y_i : variable dépendante / expliquée / de résultat
- x_i : variable indépendante / explicative / régresseur / covariable
- e_i : terme d'erreur / inobservé

Chemin de pensée

1. Intuition

« Ajuster une droite aux données »

2. Estimation par MCO

Choisir b_0 et b_1 qui minimisent la somme des carrés des résidus

3. Hypothèses du modèle

Sur le modèle de population : $y_i = \beta_0 + \beta_1 x_i + e_i$

4. Propriétés des estimateurs MCO

Algébriques (aujourd'hui) $\longrightarrow$ **Statistiques** (chapitre 5)

[Hypothèse 1] Linéarité dans les paramètres

[H1] Le modèle est linéaire dans les paramètres :

$$y_i = \beta_0 + \beta_1 x_i + e_i$$

👉 y est une combinaison **linéaire des paramètres** β_0, β_1 .

⚠️ x peut être **transformé** : il n'existe aucune restriction sur la forme que doit prendre x .

✅ Linéaire dans les paramètres

$$y_i = \beta_0 + \beta_1 \sqrt{x_i} + e_i$$

$$y_i = \beta_0 + \beta_1 x_i^2 + e_i$$

$$\log y_i = \beta_0 + \beta_1 \log x_i + e_i$$

❌ Non linéaire dans les paramètres

$$y_i = \beta_0 + x_i^{\beta_1} + e_i$$

$$y_i = \beta_0 + \exp(\beta_1 x_i) + e_i$$

$$y = 1/(\beta_0 + \beta_1 x) + u$$


Relations non linéaires dans les données ?

- Nous pouvons prendre en compte les relations non linéaires dans les régressions.
- On peut, par exemple, ajouter un terme *d'ordre supérieur* comme ceci :

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + e_i$$

- C'est alors une **régression linéaire multiple** (prochain cours !).

Linéarité dans les paramètres $\neq$ relation linéaire entre x et y



[Hypothèse 2] Échantillon aléatoire

Le modèle décrit une relation dans la **population** :

$$y_i = \beta_0 + \beta_1 x_i + e_i$$

Mais nous n'observons qu'un **échantillon** de n observations :

$$\{(x_i, y_i) : i = 1, \dots, n\}$$

[H2] Échantillon aléatoire : les observations (x_i, y_i) sont **indépendantes et identiquement distribuées (i.i.d.)**.

- **Indépendantes** : l'observation d'un individu ne dépend pas de celle d'un autre.
- **Identiquement distribuées** : toutes les observations proviennent de la **même population**.

[Hypothèse 3] Espérance conditionnelle nulle

$$y_i = \beta_0 + \beta_1 x_i + e_i$$

- Avec une constante β_0 , on peut supposer que l'erreur a une moyenne nulle :

$$E(e) = 0$$

[H3] Quelle que soit la valeur de x , l'erreur a une espérance conditionnelle nulle :

$$E(e \mid x) = 0$$

Autrement dit, les facteurs non observés contenus dans e ne varient pas systématiquement, en moyenne, avec x .

Et si $E(e \mid x) \neq 0$?

$$\text{salaire}_i = \beta_0 + \beta_1 \text{éducation}_i + e_i$$

- Il faut réfléchir à ce qui peut être contenu dans e_i : **ambition, capacités, santé, conditions du marché du travail local, etc.**
- L'hypothèse $E(e \mid x) = 0$ implique que, **quel que soit le niveau d'éducation** :

$$E(e \mid \text{décrocheur scolaire}) = E(e \mid \text{diplômé d'un master}) = 0$$

- À l'inverse, $E(e \mid x) \neq 0$ signifie que certains facteurs contenus dans e sont **systématiquement liés au niveau d'éducation**.
 - Ex: si l'ambition influence le salaire et est liée au niveau d'éducation, alors $E(e \mid x) \neq 0$.
- **L'hypothèse $E(e \mid x) = 0$ garantit que les estimateurs MCO sont non biaisés !**

[Recap Hypothèses] Régression linéaire simple

$$y_i = \beta_0 + \beta_1 x_i + e_i$$

- **[H1]** Modèle *linéaire* dans ses paramètres.
- **[H2]** Échantillon *aléatoire* : $\{(x_i, y_i) : i = 1, \dots, n\}$ où les (x_i, y_i) sont i.i.d.
- **[H3]** Moyenne conditionnelle nulle : $E(e \mid x) = 0$.
- **[H4]** Variabilité de x : x ne doit pas être constant dans l'échantillon ($x_i \neq c$).
 - Sans variation de x , on ne peut pas estimer la relation entre x et y .

Sous les hypothèses H1–H4, les estimateurs MCO (β_0) et (β_1) sont sans biais.

$$E(b_0) = \beta_0 \quad \text{et} \quad E(b_1) = \beta_1$$

Une 5^e hypothèse : vers le théorème de Gauss-Markov

- **[H5] Homoscédasticité** : $Var(e \mid x)$ est **constante** (ne dépend pas de x).

[H1]-[H5] ensemble forment le **théorème de Gauss-Markov** : sous ces 5 hypothèses, l'estimateur MCO est **BLUE** (Best Linear Unbiased Estimator).

Lien avec les propriétés statistiques :

- **Sans biais** ($\mathbb{E}(b_0) = \beta_0, \mathbb{E}(b_1) = \beta_1$) : déjà garanti par [H1]-[H4].
- **Efficace** (variance **minimale** parmi tous les estimateurs linéaires non biaisés) : nécessite en plus [H5].
- *À suivre au chapitre 5 ...*

Plan du cours

1. Introduction I : l'intuition derrière la droite de régression
2. Introduction II : formalisation modèle de régression linéaire simple
3. Estimation par moindres carrés ordinaires (MCO)
4. Le modèle de régression linéaire simple (et hypothèses)
5. **Estimation en Stata**
6. Propriétés algébriques de l'estimateur des MCO

MCO (OLS) avec **Stata**

- En **Stata**, les régressions OLS sont estimées à l'aide de la fonction **regress** (**reg**).
- Voici comment cela fonctionne :

```
1 regress dependent_variable independent_variable
```

Taille de la classe et performance des élèves

Estimons le modèle suivant par MCO :

$$\text{average math score}_i = \beta_0 + \beta_1 \text{class size}_i + e_i$$

```
1 /* import data */
2 use "https://www.dropbox.com/s/wwp2cs9f0dubmhr/grade5.dta?dl=1", replace
3 collapse (mean) avgmath_cs=avgmath avgverb_cs=avgverb, by(classsize)
4
5 /* OLS regression of average maths score on class size */
6 regress avgmath_cs classsize
```

. regress avgmath_cs classsize

Source	SS	df	MS	Number of obs	=	38
Model	170.023082	1	170.023082	F(1, 36)	=	13.66
Residual	448.119006	36	12.4477502	Prob > F	=	0.0007
Total	618.142088	37	16.7065429	R-squared	=	0.2751
				Adj R-squared	=	0.2549
				Root MSE	=	3.5281

avgmath_cs	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
classsize	.191271	.0517536	3.70	0.001	.0863098	.2962322
_cons	61.10917	1.435982	42.56	0.000	58.19686	64.02147

Moindres Carrés Ordinaires (MCO) : prédiction

Cela implique (sans l'indice i par simplicité) :

$$\hat{y} = b_0 + b_1 x$$

$$\overline{\text{average math score}} = b_0 + b_1 \cdot \text{class size}$$

$$\overline{\text{average math score}} = 61.11 + 0.19 \cdot \text{class size}$$

Moindres Carrés Ordinaires (MCO) : prédiction

Quel est le score moyen prédit pour une classe de 15 élèves ?

$$\text{average math score} = 61.11 + 0.19 \cdot 15$$

$$\text{average math score} = 63.98$$

	classsize	avgmath_cs	pred_avgmath_cs	error
1	5	74	62.06552	11.93448
2	8	52.885	62.63934	-9.754337
3	9	60.254	62.8306	-2.576607
4	10	69.7725	63.02188	6.750622
5	11	65.235	63.21315	2.021854
6	12	60.66666	63.40442	-2.737755
7	13	64.38499	63.59569	.7893066
8	14	62.87455	63.78696	-.9124146
9	15	57.72909	63.97823	-6.249138

Exercice 2 : régression par MCO

08:00

Après avoir agrégé les données au niveau de la taille de la classe avec le code suivant :

```
1 collapse (mean) avgmath_cs=avgmath avgverb_cs=avgverb, by(classsize)
```

1. Régresser le score moyen en lecture (*verbal*) (variable dépendante) sur la taille de la classe (variable indépendante). Interpréter les coefficients.
2. Calculer les coefficients OLS b_0 et b_1 de la régression précédente en utilisant les formules vues plus haut. (*Indice* : vous devez utiliser les commandes `corr` et `summarize` .)
3. Quel est le score de lecture moyen prédit quand la taille de la classe est égale à 0 ? (est-ce que ce chiffre a du sens ?!)
4. Quel est le score de lecture moyen prédit quand la taille de la classe est égale à 30 ?

Plan du cours

1. Introduction I : l'intuition derrière la droite de régression
2. Introduction II : formalisation modèle de régression linéaire simple
3. Estimation par moindres carrés ordinaires (MCO)
4. Le modèle de régression linéaire simple (et hypothèses)
5. Estimation en Stata
6. **Propriétés algébriques de l'estimateur des MCO**

Propriétés de l'estimateur MCO

- L'estimateur MCO possède des **propriétés algébriques** de base.
 - Ces propriétés ne dépendent pas d'hypothèses concernant les propriétés statistiques de y , x ou e .

À partir de l'estimation par MCO, nous pouvons calculer :

Valeur prédite : $\hat{y}_i = b_0 + b_1 x_i$

Résidus (estimés) : $\hat{e}_i = y_i - b_0 - b_1 x_i = y_i - \bar{y} - b_1 (x_i - \bar{x})$

Droite de régression : $\hat{y} = b_0 + b_1 x$

Propriétés algébriques de l'estimateur MCO : Prédictions et résidus

1. La somme ou moyenne des résidus est 0.

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n \hat{e}_i &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i) \\ &= \bar{y} - \frac{1}{n} \sum_{i=1}^n \hat{y}_i = 0\end{aligned}$$

2. Covariance entre la variable indépendante et résidus est 0.

$$\sum_{i=1}^n x_i \hat{e}_i = 0$$

$$\text{cov}(x, \hat{e}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \hat{e}_i = \frac{1}{n} \sum_{i=1}^n x_i \hat{e}_i = 0.$$

4. La moyenne de $\hat{y}_i$ est égale à $\bar{y}$, d'après (1).

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n \hat{y}_i &= \frac{1}{n} \sum_{i=1}^n (b_0 + b_1 x_i) \\ &= b_0 + b_1 \bar{x} = \bar{y}\end{aligned}$$

5. Covariance entre la prediction et les résidus est 0, d'après (1) et (2).

$$\begin{aligned}\text{cov}(\hat{y}_i, \hat{e}_i) &= \text{cov}(b_0 + b_1 x_i, \hat{e}_i) \\ &= b_1 \text{cov}(x_i, \hat{e}_i) = 0\end{aligned}$$

$$\text{car } \text{cov}(a + cx, y) = c \text{cov}(x, y).$$

Qualité d'ajustement (*Goodness of Fit*)

- Au niveau individuel i : $y_i = \hat{y}_i + \hat{e}_i$. On en déduit la décomposition suivante :

$$SCT = SCE + SCR$$

Variation totale = Expliquée par le modèle + Non expliquée par le modèle

- Cette décomposition repose sur les **propriétés algébriques des MCO** (#1 et #4) :
⇒ Ces deux propriétés découlent des conditions du premier ordre du problème de minimisation des MCO.

Qualité d'ajustement (*Goodness of Fit*)

$$SCT = SCE + SCR$$

Variation totale = Expliquée par le modèle + Non expliquée par le modèle

- SCT = Somme des Carrés Totaux = $\sum_{i=1}^n (y_i - \bar{y})^2$
 - Mesure le degré de dispersion des y_i dans l'échantillon.
- SCE = Somme des Carrés Expliqués = $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
 - Mesure le degré de dispersion des $\hat{y}_i$ dans l'échantillon.
- SCR = Somme des Carrés des Résidus = $\sum_{i=1}^n \hat{e}_i^2$

Qualité d'ajustement (*Goodness of Fit*) : coefficient de détermination (ou R^2)

- Le R^2 mesure l'**adéquation du modèle aux données**.
- Fraction de la variation de y qui est expliquée par x au sein de l'échantillon.

$$R^2 = \frac{\text{Variance expliquée}}{\text{Variance totale}} = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT} \in [0, 1]$$

avec $SCE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ et $SCT = \sum_{i=1}^n (y_i - \bar{y})^2$.

- R^2 proche de 1 indique un **très haut pouvoir explicatif** du modèle.
- R^2 proche de 0 indique un **très faible pouvoir explicatif** du modèle.

Qualité d'ajustement (*Goodness of Fit*) & causalité

- *Interprétation* : un R^2 de 0.5, par exemple, signifie que la variation de x « explique » 50 % de la variation de y .
- ⚠ Un R^2 faible **NE** signifie **PAS** que le modèle est inutile !
 - Rappel : l'économétrie s'intéresse aux mécanismes causaux, et pas uniquement aux prédictions !
- ⚠ Le R^2 n'indique **PAS** si la relation est causale !

Exercice 3 : R^2 et qualité d'ajustement

08:00

1. Régresser `avgmath_cs` sur `classsize`. Quel est le R^2 ?
2. Calculer la valeur prédite de `avgmath_cs` (appelez-la `avgmath_cs_pred`) et le résidu (`residu`). Quelle est la valeur moyenne du résidu ?
3. Calculer la variance expliquée et la variance totale pour cette régression. En déduire le R^2 .
4. Calculer le carré de la corrélation entre `classsize` et `avgmath_cs`. Quelle propriété relie le R^2 et la corrélation dans une régression univariée ?
5. Répéter la question 1 pour `avgverb_cs`. Pour quelle matière la variance de la taille de la classe explique-t-elle le plus la variance du score des étudiants ?

Concepts à retenir

1. Comment écrire le modèle de régression simple.
2. Le problème de minimisation dont l'estimateur des MCO est une solution.
3. Les hypothèses statistiques de base du modèle.
4. Les propriétés algébriques de l'estimateur des MCO.
5. Le concept du R^2 , ainsi que les notions de SCT (somme des carrés totaux), SCE (somme des carrés expliqués) et SCR (somme des carrés des résidus).

Où en sommes-nous de notre quête de la causalité ?

✅ Comment gérer les données ? Ouvrez-les, ordonnez-les, visualisez-les...

⚠️ **Comment résumer une relation entre plusieurs variables ?** Régression linéaire simple... à suivre

❌ Qu'est-ce que la causalité ?

❌ Comment faire si nous n'observons qu'une partie de la population ?

❌ Nos résultats sont-ils uniquement dus au hasard ?

❌ Comment trouver de l'exogénéité en pratique ?

À la semaine prochaine !

CONTACT

natalia.bermudez@uliege.be

Un grand merci à [Malka Guillot](#) pour avoir partagé les supports de ce cours, ainsi qu'à [Florian Oswald](#) et à toute l'équipe de ScPoEconometrics pour leur livre et leurs [ressources](#).